

MarketPilot — Plateforme Cloud d'Analyse Temps Réel des Marchés Financiers

Rapport de projet — module Cloud / Big Data, 2026

Plateforme complète de collecte, traitement, prédiction et visualisation de données boursières temps réel, déployable en local (Docker) ou sur AWS. **Pipeline** : Finnhub → Producer → Kafka → Consumer → CSV/S3 → Dashboard Streamlit + ML

Sommaire

1. Contexte et objectifs
 2. Architecture générale
 3. Chaîne de données temps réel
 4. Modélisation Machine Learning - 4.1 Données, cible et variables - 4.2 Comparaison des modèles - 4.3 Pouvoir discriminant : ROC et précision-rappel - 4.4 Calibration et distribution des probabilités - 4.5 Matrice de confusion - 4.6 Optimisation AutoML (Optuna) - 4.7 Courbe d'apprentissage et importance des variables
 5. Backtest out-of-sample
 6. Dashboard et fonctionnalités applicatives
 7. Déploiement AWS
 8. Sécurité
 9. Résultats, limites et perspectives
-

1. Contexte et objectifs

L'objectif du projet est de fournir, via une architecture cloud scalable, une solution **temps réel** d'analyse et de prédiction sur des flux boursiers : accessible, fiable et facilement déployable. Le périmètre couvre toute la chaîne de valeur, de l'**ingestion** des cotations jusqu'à la **décision d'investissement assistée par IA**, en passant par le **traitement en flux**, la **modélisation ML** et la **restitution** dans un dashboard interactif.


Trois exigences ont structuré la conception :

- **Temps réel** : les cotations doivent transiter par un bus de messages (Kafka) et être enrichies au fil de l'eau, avec un mécanisme de repli (fallback CSV) garantissant la continuité de service.
- **Rigueur méthodologique** en ML : validation *walk-forward* (respect de l'ordre temporel), comparaison systématique de plusieurs familles de modèles, et **backtest out-of-sample avec coûts de**


transaction pour mesurer la valeur économique réelle du signal, au-delà des métriques de classification.

- **Portabilité** : lancement en une commande via `docker compose`, et déploiement AWS documenté (EC2, S3, SageMaker, Athena, CloudWatch).

2. Architecture générale



Chaîne ML (offline + inférence locale)



Le choix d'une **inférence locale** (chargement de `direction_model.joblib` par le dashboard) plutôt qu'un endpoint SageMaker permanent évite tout coût de serving continu, tout en conservant l'entraînement managé et scalable sur SageMaker.

3. Chaîne de données temps réel

Composant	Rôle
Producer	Récupère les cotations Finnhub, publie sur Kafka (topic <code>market.quotes.raw</code>), backup CSV, <i>rate-limiting</i> et déduplication.
Kafka	Transport temps réel résilient (Kafka + ZooKeeper + Kafka UI via docker-compose).
Consumer	Nettoie et enrichit chaque tick (<code>delta_abs</code> , <code>delta_pct</code> , <code>direction</code>), écrit <code>processed_quotes.csv</code> , avec fallback CSV si Kafka est silencieux.
Dashboard	Visualisation, ML, recommandations, alertes, authentification (Streamlit multi-pages).
Worker d'alertes	Service autonome qui envoie les emails sur seuils, sans qu'un utilisateur soit connecté.

Chaque message publié contient le symbole, les prix (`current` , `high` , `low` , `open` , `previous_close`), l'horodatage Finnhub, l'horodatage d'ingestion et la source.


4. Modélisation Machine Learning

4.1 Données, cible et variables

- **Historique** : OHLCV quotidien via yfinance sur **5 ans**, pour 5 valeurs (`AAPL` , `MSFT` , `TSLA` , `GOOGL` , `AMZN`).
- **Cible** : direction du prix à l'horizon **1 jour**, avec un seuil de neutralité de **5 bps** (`threshold_bps = 5.0`) — problème de **classification binaire** (hausse / baisse).
- **Variables** : indicateurs techniques dérivés des séries (rendements décalés, moyennes mobiles, volatilité, RSI, etc. — voir `src/ml/features.py`).
- **Validation** : *walk-forward cross-validation* à **5 splits**, qui respecte l'ordre chronologique et interdit toute fuite d'information du futur vers le passé.

4.2 Comparaison des modèles

Neuf modèles ont été comparés sur la même validation walk-forward. La métrique de référence est la **ROC AUC moyenne** ($\pm$ écart-type inter-folds).




Rang	Modèle	ROC AUC	Accuracy	F1	Log-loss
1	XGBoost ★	0.5254 $\pm$ 0.011	0.5187	0.5447	0.7101
2	LightGBM	0.5228 $\pm$ 0.019	0.5113	0.5293	0.7108
3	Voting	0.5224 $\pm$ 0.017	0.5134	0.5386	0.7093
4	MLP	0.5218 $\pm$ 0.015	0.5144	0.5544	0.7038
5	Random Forest	0.5208 $\pm$ 0.011	0.5152	0.5305	0.6949
6	GBDT	0.5206 $\pm$ 0.018	0.5207	0.5489	0.7126
7	Extra Trees	0.5203 $\pm$ 0.010	0.5123	0.5249	0.6931
8	LogReg	0.5068 $\pm$ 0.021	0.5093	0.5196	0.7003
9	AdaBoost	0.5011 $\pm$ 0.028	0.5038	0.5530	0.7560


Lecture. Le meilleur modèle retenu est **XGBoost** (AUC $\approx$ 0.525). Tous les modèles se situent légèrement au-dessus du hasard (0.5), ce qui est **attendu et sain** pour de la prédiction de direction quotidienne : un AUC massivement supérieur à 0.5 sur ce type de cible signifierait une fuite de données plutôt qu'un vrai signal. Les modèles à base d'arbres boostés (XGBoost, LightGBM) dominent légèrement la régression logistique et AdaBoost.

4.3 Pouvoir discriminant : ROC et précision-rappel

Les courbes suivantes sont calculées **out-of-fold** (prédictions hors échantillon d'entraînement) sur le meilleur modèle.




La courbe ROC se tient au-dessus de la diagonale aléatoire, confirmant un pouvoir discriminant faible mais réel et cohérent avec l'AUC de 0.525.




La courbe précision-rappel se compare à la *base rate* (proportion de hausses). L'écart positif, quoique modeste, indique que le modèle apporte une information au-delà de la simple fréquence de base des hausses.

4.4 Calibration et distribution des probabilités




La **calibration** mesure si une probabilité prédite de, par exemple, 0.6 correspond bien à ~60 % de hausses observées. Une courbe proche de la diagonale signifie que les probabilités sont **fiables** — condition essentielle pour piloter des seuils de décision (alertes, recommandations) et un backtest.



La distribution des probabilités prédites, séparée selon l'issue réelle (hausse / baisse), montre un **léger décalage** des probabilités vers la droite pour les hausses réelles : c'est la traduction visuelle du signal faible mais exploitable.


4.5 Matrice de confusion



Au seuil neutre de 0.5, la matrice de confusion résume les vrais/faux positifs et négatifs. Elle confirme une accuracy d'environ **52 %**, cohérente avec le tableau comparatif. Le vrai enjeu n'est pas ce seuil symétrique mais le **choix d'un seuil de décision** adapté à la stratégie (cf. backtest à seuil 0.55).

4.6 Optimisation AutoML (Optuna)


Une recherche automatique d'hyperparamètres a été menée avec **Optuna** (60 essais).




- **Meilleur essai** : #19, **AUC = 0.5249**
- **Modèle** : Extra Trees (`n_estimators=124` , `max_depth=8` , `min_samples_leaf=16`)
- **Essais** : 60

L'AutoML converge vers un AUC (≈ 0.525) du même ordre que XGBoost entraîné manuellement, ce qui **confirme la robustesse du plateau de performance** : le levier d'amélioration n'est pas l'hyperparamétrage mais le **cadre du problème** (horizon, features, cible).

4.7 Courbe d'apprentissage et importance des variables




La courbe d'apprentissage (AUC train vs validation en fonction du nombre d'arbres) permet de diagnostiquer le **sur-apprentissage** : l'AUC d'entraînement continue de monter tandis que l'AUC de validation plafonne, ce qui justifie une profondeur limitée (`max_depth=3`) et une régularisation par sous-échantillonnage.



Le classement des variables (top 15 par importance XGBoost) indique quels indicateurs techniques portent le plus de signal, et oriente le travail futur de *feature engineering*.

5. Backtest out-of-sample

Au-delà des métriques de classification, un **backtest** mesure la valeur économique du signal. Protocole : entraînement sur **5 ans** (2016–2021), test out-of-sample sur **2021-06-17 → 2026-04-30**, seuil de décision **0.55**, coûts de transaction **2 bps** par trade. La stratégie est comparée à un **Buy & Hold**.



Symbole	Rdt stratégie	Rdt Buy & Hold	Sharpe strat.	Sharpe B&H	Max DD strat.	Max DD B&H	Hit rate	Trades
AAPL	+83.8 %	+105.9 %	0.68	0.68	-27.2 %	-33.4 %	53.0 %	265
MSFT	-13.2 %	+56.3 %	-0.01	0.48	-37.7 %	-37.6 %	50.3 %	249
TSLA	+119.9 %	+85.7 %	0.58	0.51	-69.3 %	-73.6 %	54.7 %	304
GOOGL	+13.6 %	+216.1 %	0.23	0.91	-44.3 %	-44.3 %	52.9 %	284
AMZN	+78.4 %	+51.9 %	0.58	0.42	-30.6 %	-56.1 %	50.5 %	396

Lecture. Les résultats sont **contrastés** et honnêtes :

- Sur **TSLA** et **AMZN**, la stratégie **bat le Buy & Hold** en rendement *et* en Sharpe, tout en **réduisant le drawdown maximal** (protection en marché baissier grâce à l'exposition partielle).
- Sur **GOOGL** et **MSFT**, elle **sous-performe** nettement : le modèle rate une partie des fortes tendances haussières (le coût d'être hors marché).
- La **réduction du drawdown** est le bénéfice le plus systématique (AAPL, TSLA, AMZN), cohérent avec une exposition moyenne de ~55–65 % du temps.

Conclusion économique : le signal a une **valeur défensive** réelle (moindre drawdown, meilleur Sharpe sur certaines valeurs) mais **ne surperforme pas de façon systématique** — ce qui est un résultat crédible et non sur-vendu pour un signal quotidien.

6. Dashboard et fonctionnalités applicatives

Dashboard **Streamlit multi-pages** :

Page / module	Description
Accueil / Tendances	Vue de marché, cotations et indicateurs.
Opportunités / Signal IA	Probabilités de hausse par valeur, issues du modèle.
Recommandations	Profil de risque adaptatif (feedback utilisateur), métriques (volatilité, Sharpe, drawdown).
Coach IA / Assistant LLM	Passerelle configurable OpenAI / Anthropic / Groq.
Alertes	Notifications email automatiques sur seuils de probabilité ML (worker autonome, anti-spam).
Activité pipeline	Supervision de la chaîne d'ingestion.
Mon compte	Authentification (login/signup), préférences par utilisateur.

7. Déploiement AWS

- **EC2** : instances pour Kafka, producer/consumer et dashboard (services systemd + docker-compose).
- **S3** : données brutes/traitées et artefacts de modèle (`model-artifacts/model.tar.gz`).
- **SageMaker** : Training Jobs à la demande (container SKLearn, `ml.m5.large`), walk-forward CV et sélection automatique du meilleur modèle.
- **Athena** : requêtes SQL sur les données S3.
- **CloudWatch** : logs et monitoring.

Le projet est également **dockerisé** : `docker compose up` lance l'ensemble en une commande.

8. Sécurité

- Mots de passe hachés en **PBKDF2-HMAC-SHA256 salé** (200 000 itérations).
 - Secrets (`.env`), données utilisateurs (`users.json`) et logs d'alertes **exclus du dépôt** (`.gitignore`).
 - Gestion des accès AWS via **IAM** (rôle SageMaker dédié, security groups EC2).
-

9. Résultats, limites et perspectives

Résultats clés

- Chaîne temps réel complète et résiliente (Kafka + fallback CSV), déployable en une commande.
- Comparaison rigoureuse de **9 modèles** en walk-forward ; meilleur modèle **XGBoost** (AUC ≈ 0.525), confirmé par l'AutoML Optuna (AUC ≈ 0.525).
- **Backtest out-of-sample avec coûts** : valeur défensive avérée (réduction du drawdown, surperformance sur TSLA/AMZN), sans surperformance systématique.

Limites

- Le signal de direction quotidienne reste **proche du hasard** (AUC ≈ 0.52) — attendu pour cette cible ; le principal levier est le **cadrage** (horizon, features, définition de la cible), pas l'hyperparamétrage.
- Backtest sur **5 valeurs** et une seule fenêtre de test ; pas de coûts de slippage variables.

Perspectives

- Ré-entraînement planifié et automatisé, exposition d'une **API REST** d'inférence.
- Sources de données additionnelles (fondamentaux, sentiment, order book).
- Passage à **MSK** (Kafka managé) et à un stockage base de données pour l'historique.
- Élargissement de l'univers de valeurs et validation multi-fenêtres du backtest.